中国药科大学本科生毕业论文（设计）开题报告

学生姓名	邓凯杰	学 号	2020221999	专 业	信息管理与信息系统
指导教师姓 名	武小川	指导教师职 称	讲师	实习单位名 称	中国药科大学
课题名称	面向复杂版式文档的端到端多模态 RAG 系统设计与实现-以医药学文献为例				
课题性质	☐ 基础研究 ☐应用课题 ✓设计型 ☐调研综述 ☐理论研究				

开题报告内容：（包括拟研究或解决的问题、采用的研究手段及文献综述，不少于 2000 字）

1 选题依据及其意义：

1.1 研究背景

随着大型语言模型（Large Language Model，LLM[1]）的飞速发展，检索增强生成（Retrieval-Augmented Generation ，RAG[2]）已成为解决大模型“知识幻觉”的核心范式。然而，面对真实工业场景与学术领域中普遍存在的复杂版式文档（PDF、PPTX 等），传统 RAG 系统面临着严重的性能瓶颈。以《药用高分子材料学》等医药学教材为例，其格式繁杂，包含密集的图表、公式、嵌套列表与多级标题。传统的纯文本 OCR 提取会彻底破坏文档的物理拓扑结构与图文逻辑关联，导致检索系统丢失物理空间布局信息（Bounding Box）和图像语义。

此外，医疗提问往往具有高度口语化特征，与教材严谨的学术表达之间存在显著的“词汇鸿沟”，传统基于稀疏检索（如 BM25[3]）或单一密集检索（如 DPR[4]）的技术难以满足高召回率需求。同时，当前大多数开源 RAG 系统缺乏端到端的多模态处理流水线，无法建立跨模态的语义连接。因此，开发一套能够无缝兼容泛格式文档、保留细粒度递归 DOM 树结构、并融合视觉语言模型（Vision-Language Model，VLM[5]）与假设文档嵌入（Hypothetical Document Embeddings ，HyDE[6]）、基于 Cross-Encoder[7]重排序与倒数排序融合（Reciprocal Rank Fusion，RRF[8]）等高阶检索策略的综合性多模态 RAG 系统[9]，成为了下一代文档智能领域的重要演进方向。本课题旨在设计并实现这样一套端到端系统，在基础 HyDE 架构上进一步探索多视角扩展机制，并以结构极其复杂的医药学专业教材作为核心测试基准。

1.2 研究意义

本课题立足于下一代文档智能处理的前沿，具有以下核心价值：

（1） 构建端到端的多模态处理流水线

引入成熟的全格式文档版面分析引擎（如 Marker 等），将异构文档逆向工程为包含完整版式元素的结构化 JSON 树。这突破了传统 RAG 系统在处理复杂排版时仅限纯文本提取的局限，实现了文档级的高保真信息重构。同时，在此基础上，本文提出并构建了一套自动化的多模态医药学评测基准构建管线。

（2） 实现跨模态内容的智能融合与高阶检索

针对图像内容，应用视觉语言大模型（VLM）进行语义特征提取，将视觉描述无缝嵌入结构化文本切片中，以建立跨模态的语义关联。在检索策略上，引入并优化了 Multi-HyDE 与交叉编码器重排序（Cross-Encoder Rerank）的级联架构。该架构创新性地融合了“多视角查询扩展”机制，通过预设多维专家视角（如概念定义、底层机制等），将单一提问转化为高维假设性语义特征。这一策略成功跨越了用户口语提问与严谨医药术语间的词汇鸿沟，旨在有效提升复杂医药术语场景下的信息定位与精准匹配能力。

（3） 拓展空间感知的知识溯源评估体系

针对现有 RAG 评测仅关注文本语义的局限，依托解析引擎提供的物理坐标边界框（BBox），借鉴计算机视觉领域的交并比（IoU[10]）概念与 NDCG[11] 的累积增益思想，探索性

构建了“页级空间交并比（Page-Aware Spatial IoU）”及“加权空间归一化重合度（Spatial NDCG@K）”等联合评估指标。该评估体系使系统不仅能生成专业解答，还能在原始文献的图像界面上实现精确的版面级物理映射，从而极大增强医学信息溯源的可靠度。

综上所述，本研究不仅具有技术创新性，还能满足实际应用需求，兼具重要的理论意义和实用价值。

2. 研究现状与发展趋势

当前，RAG 系统的发展正经历从“纯文本语义检索”向“全文档多模态智能理解”的代际跨越。在文档解析底座方面，传统的 PDF 文本提取库正逐渐被淘汰。业界趋向于采用具备深度学习版面分析能力的工具（如 Marker、MinerU[12]），它们能将复杂的文档（包括去除页眉页脚伪影、还原内联数学公式）快速且准确地转换为 Markdown 或嵌套 JSON 树，这为下游的高级检索提供了极高质量的结构化数据字典。

在底层向量检索机制上，基于分层可导航小世界（Hierarchical Navigable Small Worlds, HNSW[13]）算法的近似最近邻搜索已被 Chroma、Qdrant 等主流数据库广泛采用，并常结合标量量化等技术提升高维向量的检索效率。在高级检索策略（Advanced RAG）方面，Gao 等人提出的 HyDE 通过 LLM 生成假设性文档进行密集检索，极大提升了零样本检索的召回表现。在检索的后处理阶段，多路召回结果常采用 RRF 算法进行位置权重的初步整合；而依靠深层跨注意力机制（Cross-Attention）精确计算语义相似度的 Cross-Encoder 重排序技术，则被广泛视为弥补双编码器交互不足的核心手段[14]。

在多模态检索架构上，诸如 RAG-Anything[15]等系统提出了完整的跨模态解析理念。学术界前沿如 ColPali[16]虽提出了通过 VLM 直接对页面图像进行多向量编码的方案，展现出极高的版面理解上限，但其极高的向量维度与计算资源开销限制了应用。因此，在当前工程落地中，采用“结构化解析 + VLM 特征提取 + 融合向量检索”的端到端管线（Pipeline）模式是兼顾精度与计算性价比的最优解。

在评估体系方面，Ranx[17] 等框架标准化了 Recall、MRR、NDCG 等语义检索与排序指标的计算；而 Ragas[18] 框架开创了对生成阶段“忠实度（Faithfulness）”的自动化评测。然而，探索将物理版面重合度（BBox）纳入评价体系，以衡量系统的“空间寻址能力”，正成为多模态 RAG 研究的新兴趋势。

3.研究思路与方法

通过查阅相关前沿文献与开源项目，结合底层算法原理进行系统设计，借助大语言模型辅助技术攻关，逐步解决多模态数据处理与高阶检索架构的工程难题。

3.1 研究目标：

本设计并实现一款针对图片型医药学教材的多模态增强检索软件系统。通过自动化提取包含空间坐标和层级结构的知识树，运用多路级联高阶检索算法，实现高准确度的医学问答与页级别的精确版面物理溯源。

3.2 具体步骤：

(1) 文档结构解析与多模态特征融合

利用 Marker 工具对多本医药学教材进行结构化提取，构建包含 children 字段递归结构的文档 DOM 树，并保留各 Chunk 的 id 与 section_hierarchy。运用 VLM 对提取的图像块生成视觉语义描述（过滤无关元素），并与文本特征进行深度融合存入文档节点。

(2) 高质量数据集自动化构建

设计大模型驱动的数据生成管线。通过抽样教材图像，利用 VLM 逆向生成多维度的医药学 QA 对（包含推理步骤与参考文本）。运用启发式文本匹配算法（基于 Python 标准库 difflib

的差异化模糊匹配）在全量文档树中进行精确坐标锚定，结合语义相似度扩展构建包含真实上下文与物理边界框（BBox）的黄金测试集。

(3) 级联检索策略设计与实现

构建从基础到高阶的实验对比路径。核心检索架构采用：依托多假设文档嵌入（Multi-HyDE）并结合多视角查询扩展机制，负责高维语义的宽域召回，以跨越口语与专业词汇鸿沟；随后级联基于交叉编码器（Cross-Encoder）的重排序模块,负责末端的细粒度高精语义鉴别，并辅以 RRF 算法保障多路召回的鲁棒性与排序稳定性。

(4) 多维评估系统集成

结合 Ranx 评估 Recall、MRR、Recall 等语义检索与排序指标，结合 Ragas 评估忠实度（Faithfulness）等生成指标。同时，构建定制化空间定位评估模块，将经典的 IoU 与 NDCG 指标计算思想延伸至物理版面寻址任务中——以 IoU 衡量空间边界重合度，以 NDCG 引入排序位置加权，计算 Page-Aware Spatial IoU 与 Spatial NDCG@K，实现端到端的自动化性能回测。

3.3 研究方法：

(1) 系统实现

基于 Python 语言与 LangChain 框架编排核心逻辑，使用支持 HNSW 索引的 Chroma 等向量数据库实现底层存储与检索。

(2) 数据集准备

摆脱对现有开源数据的依赖，自主处理 6 本专业扫描版教材（累计超 3000 页，平均单本 500 页以上，高分辨率 PNG），攻克大规模非结构化文档解析难题，完成从原始图像到高质量多模态问答数据集的从零构建。

(3) 对比实验法

探索并对比不同检索架构在召回截断（Top-K）下的性能边界。实验将涵盖基础向量检索基线（Simple）、引入稀疏检索（BM25）的混合架构（Hybrid）、倒数排序融合（RRF）、多假设文档嵌入（Multi-HyDE）以及基于 Cross-Encoder 的重排序等策略，通过消融实验验证多模块级联架构的有效性。

4.拟解决问题

(1) 如何高效、无损地将图片型医药 PDF 转化为包含丰富语义（图文融合）与物理层级坐标（BBox）的结构化知识库。

(2) 如何设计并论证一套科学的空间评估指标（如 Page-Aware Spatial IoU），以量化模型在实体页面上的空间物理定位准确度。

5.系统开发技术路线

开发环境采用 Ubuntu 系统，充分调度底层计算资源。IDE 使用 VSCode，开发语言为 Python。 数据处理栈上，采用 Marker 结合大模型实现结构化解析；核心检索流水线依托 LangChain 构建。底层存储采用 Chroma 向量数据库。模型调用方面，图文解析与生成环节接入 Gemini 3 Flash API 与高性能 LLM API；向量化与精排阶段分别调用 text-embedding-v4 与 Qwen3-VL-rerank 模型。

6.进度安排

本课题研究分为四个阶段：调研阶段、开题阶段、设计阶段和论文完成阶段。

第一阶段：调研阶段（2025 年 12 月—2026 年 2 月）——调研 RAG 底层原理、向量数据库机制（HNSW）、多模态大模型及 LangChain 框架，完成 Marker 文档解析 Demo 的端到端验证。

第二阶段：开题阶段（2026 年 2 月一 2026 年 3 月)——完成 6 本教材的 Marker 树化解析；利用大模型结合启发式匹配完成海量多模态 QA 数据集的自动化构建与锚定；明确定制化空间定位评估的核心维度；完成前期预实验并撰写开题报告。

第三阶段：设计阶段（2026 年 3 月—2026 年 4 月）——全面展开消融实验，对比基础基线、基于 BM25 的混合检索、Multi-HyDE 宽域召回、Cross-Encoder 重排序等各模块性能，完成定制化空间定位评估指标并生成数据图表，完成系统闭环。

第四阶段：论文完成阶段（2026 年 5 月—2026 年 6 月）——整理全量测试集的数据结果与实验可视化，与现有开源系统（如 RAG-Anything）进行对比分析，完成论文撰写及答辩工作。

参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[2] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[J]. Advances in neural information processing systems, 2020, 33: 9459-9474.

[3] Robertson S, Zaragoza H. The probabilistic relevance framework: BM25 and beyond[M]. Now Publishers Inc, 2009.

[4] Karpukhin V, Oguz B, Min S, et al. Dense passage retrieval for open-domain question answering[C]//Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP). 2020: 6769-6781.

[5] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.

[6] Gao L, Ma X, Lin J, et al. Precise zero-shot dense retrieval without relevance labels[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 1762-1777.

[7] Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks[C]//Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019: 3982-3992.

[8] Cormack G V, Clarke C L A, Buettcher S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods[C]//Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval. 2009: 758-759.

[9] Chen W, Hu H, Chen X, et al. Murag: Multimodal retrieval-augmented generator for open question answering over images and text[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. 2022: 5558-5570.

[10] Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2010, 88(2): 303-338.

[11] Järvelin K, Kekäläinen J. Cumulated gain-based evaluation of IR techniques[J]. ACM Transactions on Information Systems (TOIS), 2002, 20(4): 422-446.

[12] Wang B, Xu C, Zhao X, et al. Mineru: An open-source solution for precise document content extraction[J]. arXiv preprint arXiv:2409.18839, 2024.

[13] Malkov Y A, Yashunin D A. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs[J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 42(4): 824-836.

[14] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A

survey[J]. arXiv preprint arXiv:2312.10997, 2023, 2(1): 32.
[15] Guo Z, Ren X, Xu L, et al. Rag-anything: All-in-one rag framework[J]. arXiv preprint arXiv:2510.12323, 2025.
[16] Faysse M, Sibille H, Wu T, et al. Colpali: Efficient document retrieval with vision language models[J]. arXiv preprint arXiv:2407.01449, 2024.
[17] Bassani E. ranx: A blazing-fast python library for ranking evaluation and comparison[C]//European Conference on Information Retrieval. Cham: Springer International Publishing, 2022: 259-264.
[18] Es S, James J, Anke L E, et al. Ragas: Automated evaluation of retrieval augmented generation[C]//Proceedings of the 18th conference of the european chapter of the association for computational linguistics: system demonstrations. 2024: 150-158.

学生签名：邓凯杰　　2026 年　3　月　8　日

指导教师意见：本课题紧扣当前大模型与多模态检索增强生成技术前沿，研究内容新颖、应用背景明确，选题将多模态 RAG 技术与医药学文献场景相结合，针对复杂版式文档解析、图文信息理解与精准生成等实际问题展开研究，具有较强的理论意义与工程应用价值。研究方案合理、技术路线清晰，工作量与难度符合本科毕业论文要求，具备可行性与创新性，前期准备工作充分，可以开题。

指导教师签名：武小川　　2026 年　3　月　8　日

实习单位意见：

负责人签名：　　年　　月　　日

填写说明

1.指导教师意见：由毕业论文（设计）指导教师填写，包括对文献综述的评语，对本课题的深度、广度及工作量的意见及对论文（设计）结果的预测；

2.实习单位意见：由校外实习单位或校内论文指导教师所属学院（处、部）签署意见。